

---

## Inteligência Computacional

---

### **Docente**

Inês Dominguês  
Carlos Pereira

### **Alunos**

Paulo Henrique Figueira Pestana de Gouveia - a2020121705  
Nuno Alexandre Almeida Santos - a2019110035

# Índice

<b>1</b>	<b>Introdução</b>	<b>1</b>
<b>2</b>	<b>Em que consiste a Computação Evolucionária?</b>	<b>1</b>
2.1	Descrição do paradigma de computação evolucionária e possíveis aplicações no contexto de treino de uma rede neuronal . . . . .	1
<b>3</b>	<b>Inteligência Swarm</b>	<b>2</b>
3.1	PSO . . . . .	2
<b>4</b>	<b>Descrição em detalhe do "Firefly algorithm" e análise comparativamente com a versão base, o PSO.</b>	<b>4</b>
4.1	FireFly . . . . .	4
4.2	Firefly algorithm . . . . .	4
4.3	Análise comparativamente a PSO . . . . .	4
<b>5</b>	<b>Análise de desempenho</b>	<b>5</b>
5.1	Aplicar e ilustrar ao algoritmo para otimização de duas funções "benchmark" a função esfera (para dimensão 2 e 3) e função de Ackley (para dimensão 2 e 3). . . . .	5
5.2	Comparar com a versão base do PSO e analisar a sensibilidade aos diferentes parâmetros do algoritmo, apresentando tabela com resultados. . . . .	5
<b>6</b>	<b>Conclusões</b>	<b>5</b>
<b>7</b>	<b>Referências</b>	<b>5</b>

# 1 Introdução

## 2 Em que consiste a Computação Evolucionária?

A evolução é um processo de otimização em que o objetivo é melhorar a capacidade de um organismo (ou sistema) sobreviver em ambientes dinâmicos e competitivos. Ao falar sobre evolução, é importante primeiro identificar a área em que a evolução pode ser definida, por exemplo, cósmica, química, estelar e planetária, sistemas de evolução orgânicos ou feitos pelo homem. Para essas diferentes áreas, a evolução pode ser interpretado de forma diferente.

A Computação Evolucionária compreende um conjunto de técnicas de busca e otimização inspiradas na evolução natural das espécies. Desta forma, cria-se uma população de indivíduos que vão reproduzir e competir pela sobrevivência. Os melhores sobrevivem e transferem suas características a novas gerações.

### 2.1 Descrição do paradigma de computação evolucionária e possíveis aplicações no contexto de treino de uma rede neuronal

Sistemas de CE resolvem problemas por meio de população, tentativa e erro, meta-heurística ou otimização estocástica. Um conjunto inicial de candidatos a solução é gerado e atualizado iterativamente: remoção das soluções menos desejadas, inserção de ruído.

Em termos técnicos, as populações de solução evoluem e se adaptam à medida que estão sujeitas à seleção e mutação naturais ou artificiais. Ou seja, melhor ajuste (a função quantifica o quão adaptável/desejável é a solução). A CE é popular na IC porque leva a soluções otimizadas em uma ampla variedade de contextos, e há muitas variantes e extensões para problemas e estruturas de dados específicos.

No contexto de redes neuronais, a computação evolutiva pode ser aplicada a soluções dadas enquanto treina a rede. No exemplo de classificação de forma geométrica usando CE, a solução evolui através de seleção e mutação natural ou artificial à medida que a rede é treinada. Isso nos permite generalizar a forma com mais precisão com o auxílio de descartar soluções menos desejáveis.

### 3 Inteligência Swarm

Conjunto estruturado de indivíduos (ou agentes) que interagem entre si. Os Indivíduos pertencentes ao swarm (enxame) interagem para atingirem um objectivo comum, de forma mais eficiente do que agindo individualmente.

Formalmente, um enxame pode ser definido como um grupo de agentes (geralmente móveis) que se comunicam entre si (seja direta ou indiretamente), agindo no seu ambiente local. Mais formalmente, inteligência Swarm é a propriedade de um sistema pelo qual os comportamentos coletivos de agentes não sofisticados interagindo localmente com seu ambiente causam o surgimento de padrões funcionais globais coerentes. O objetivo dos modelos computacionais de inteligência Swarm é modelar o simples comportamento dos indivíduos e as interações locais com o ambiente e os indivíduos vizinhos, a fim de obter comportamentos mais complexos que podem ser usados para resolver problemas complexos, principalmente problemas de otimização.

Inteligência Swarm faz uso de algoritmos de convergência baseados em fenômenos emergentes da natureza como: colônias de insetos, estratégias coletivas de peixes e pássaros e ainda comportamento auto-organizativo de partículas atômicas e subatômicas.

Por outro lado, a otimização de colônia de formigas modela o comportamento muito simples de seguir a trilha de feromônio das formigas, onde cada formiga percebe as concentrações de feromônio em sua ambiente local e age selecionando probabilisticamente a direção com maior concentração de feromônio. Daí surge o comportamento de encontrar a melhor alternativa (caminho mais curto) a partir de uma coleção de alternativas. Modelos do comportamento local de formigas que frequentam cemitérios resultam no comportamento complexo de agrupar objetos semelhantes em clusters.

#### 3.1 PSO

O algoritmo de otimização de enxame de partículas (PSO) é um algoritmo de pesquisa baseado em população baseado na simulação do comportamento social de pássaros dentro de um bando, que são denominados por partículas. Esse método se inicializa aleatoriamente, através de um conjunto de partículas com velocidades e posições aleatórias. Após essa inicialização os indivíduos são avaliados através da função de avaliação. Em um algoritmo PSO existe um conjunto de vetores cujas trajetórias oscilam em torno de uma região definida por cada melhor posição individual (PBEST) e a melhor posição dos outros (GBEST).

A posição da partícula,  $x_i$ , vai sendo atualizada de acordo com a equação:

$$x_i(t+1) = x_i(t) + w.v_i(t) + C1.rnd(PBEST - x_i(t)) + C2.rnd(GBEST - x_i(t)) \quad (1)$$


Na equação (1),  $v_i(t)$  representa o vetor velocidade da partícula  $i$  no tempo  $t$ ,  $w$  é o fator de inércia,  $rnd$  representa números aleatórios de distribuição uniforme entre 0-1,  $C1$  e  $C2$

representam respectivamente os parâmetros social e cognitivo, PBEST é a melhor posição individual e GBEST é a melhor posição social. Os parâmetros C1 e C2 ajustam o balanço entre a influência social e a aprendizagem da partícula individual.

Algoritmo de otimização de enxame de partículas (PSO) modela dois comportamentos simples: cada indivíduo (1) se move em direção seu melhor vizinho mais próximo e (2) retorna ao estado que o indivíduo experimentou ser o melhor para si mesmo. Como resultado, o comportamento coletivo que emerge é que de todos os indivíduos convergindo para o estado ambiental que é melhor para todos os indivíduos.

Exemplo:

Uma forma mais simples de explicação pode ser um bando de gaivotas telepáticas à procura da melhor fonte de comida. Todas começam num mapa distribuídas aleatoriamente, no início antes de se moverem têm velocidade zero mas sabem qual a gaivota mais próximo da solução ótima, alteram então a sua velocidade e direcção para irem nesse sentido. À medida que vão andando vão-se lembrando da sua melhor posição, usam a sua velocidade actual, a sua melhor posição e a melhor posição global para alterarem a sua velocidade e logo a sua posição para se dirigirem para a posição ótima. Como iniciaram em posições aleatórias no mapa ao dirigirem-se todas para o mesmo ponto inevitavelmente vão passar pelo ponto ótimo, alterando ao melhor global e fazendo com que todas consigam convergir nesse ponto.



## 4 Descrição em detalhe do "Firefly algorithm" e análise comparativamente com a versão base, o PSO.

### 4.1 FireFly

A maioria das espécies de vaga-lumes são capazes de brilhar produzindo flashes curtos. Considera-se que a principal função dos flashes é atrair vaga-lumes do sexo oposto e potenciais presas. Além disso, um flash de sinal pode comunicar a um predador que um vaga-lume tem um gosto amargo.

### 4.2 Firefly algorithm

Com base nas propriedades piscantes das espécies de pirilampos, Xin-She Yang [148,149] desenvolveu o Firefly Algorithm (FA) em 2008. Um sistema não linear que combina o decaimento exponencial da absorção de luz e lei do inverso do quadrado da variação de luz usa a distância. Em FA, a principal equação algorítmica para a posição é  $x_i$  (como o vetor de solução do problema) é:

$$x_i^{t+1} = x_i^t + \beta_0 e^{-\gamma r_{ij}^2} (x_j^t - x_i^t) + \alpha \epsilon_i^t \quad (2)$$

onde  $\alpha$  é um fator de escala que controla o tamanho do passo do passeio aleatório e  $\gamma$  é um parâmetro dependente de escala que controla a visibilidade do pirilampo (e o modo de busca). Além disso  $\beta_0$  é a constante gravitacional quando a distância entre dois pirilampos é zero (ou seja,  $r_{ij} = 0$ ). Este sistema é um sistema não linear que leva a recursos ricos em termos de comportamento algorítmico.

Como o brilho dos pirilampos está relacionado à paisagem objetiva usando sua posição como índice, a atratividade dos pirilampos vistos por outros depende de sua posição relativa e brilho relativo. Portanto, a beleza está nos olhos de quem vê. Portanto, comparações pareadas são necessárias para comparar todos os pirilampos.

### 4.3 Análise comparativamente a PSO

O algoritmo Firefly compartilha muitas semelhanças com algoritmos SI, como PSO. Parece ser mais eficaz na otimização multiobjetivo. O algoritmo Firefly tem cinco regras baseadas nas propriedades piscantes dos pirilampos reais:

1. Todos os vaga-lumes são capazes de se atrair independentemente do sexo;
2. A atratividade de um vaga-lume para outros indivíduos é proporcional ao seu brilho.
3. Vaga-lumes menos atraentes se movem na direção do mais atraente.
4. À medida que a distância entre dois vaga-lumes aumenta, o brilho visível de um determinado vaga-lume para o outro diminui.
5. Se um vaga-lume não vê nenhum vaga-lume que seja mais brilhante do que ele, ele se move aleatoriamente.

## 5 Análise de desempenho

- 5.1 Aplicar e ilustrar ao algoritmo para otimização de duas funções “benchmark” a função esfera (para dimensão 2 e 3) e função de Ackley (para dimensão 2 e 3).
- 5.2 Comparar com a versão base do PSO e analisar a sensibilidade aos diferentes parâmetros do algoritmo, apresentando tabela com resultados.

## 6 Conclusões

## 7 Referências